Judul Studi Kasus:

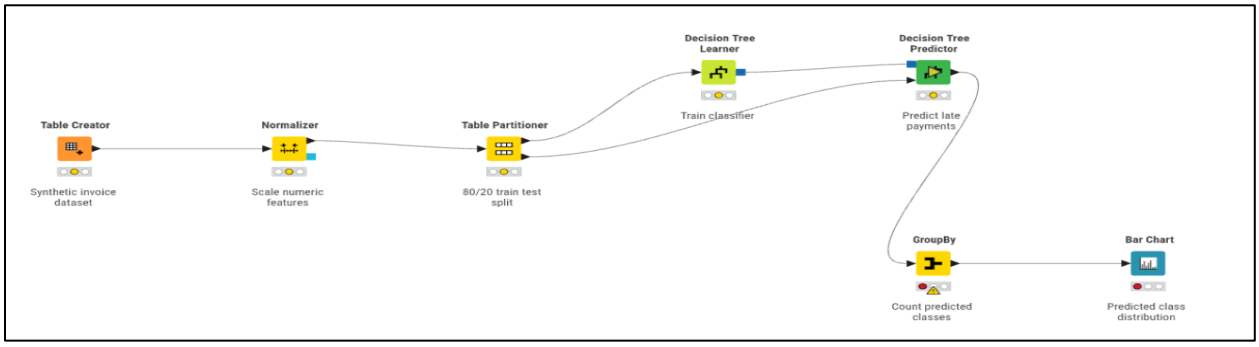
Prediksi Keterlambatan Pembayaran Tagihan (*Invoice Late Payment Prediction*)

Latar Belakang & Masalah Bisnis: Manajemen perusahaan ingin memprediksi status pembayaran *invoice* (*Late* vs *Not Late*) berdasarkan profil transaksi dan histori pelanggan untuk meminimalkan penumpukan piutang.

Fitur Data (Dihasilkan Otomatis oleh Node KNIME):

- Invoice_Amount: Nominal nilai tagihan ($)
- Payment_Terms: Tenor/jangka waktu pembayaran (hari)
- Credit_Score: Skor kredit pelanggan (300–850)
- Is_Late: Target label (Late / Not Late)

Workflow knime



Workflow KNIME tersebut menggambarkan alur kerja analisis data dan pemodelan *Machine Learning* untuk memprediksi keterlambatan pembayaran tagihan (*invoice late payment*) secara sederhana dan terstruktur. Alur diawali dengan node **Table Creator** yang berfungsi untuk memuat atau membuat dataset sintetis berisi variabel-variabel transaksi tagihan (*synthetic invoice dataset*) tanpa memerlukan berkas eksternal. Selanjutnya, data dialirkan ke node **Normalizer** untuk melakukan transformasi *feature scaling*, yaitu menyesuaikan skala nilai fitur-fitur numerik agar berada pada rentang uniform (seperti 0 hingga 1) sehingga mencegah dominasi fitur berukuran besar saat pelatihan model.

Setelah data dinormalisasi, node **Table Partitioner** membagi dataset menjadi dua bagian dengan rasio 80% untuk data pelatihan (*training set*) dan 20% untuk data pengujian (*testing set*). Data pelatihan dialirkan ke node **Decision Tree Learner** untuk melatih algoritma klasifikasi *Decision Tree* agar dapat mengenali pola keterlambatan pembayaran. Model pohon keputusan yang telah dilatih tersebut kemudian dihubungkan ke node **Decision Tree Predictor** bersamaan

dengan 20% data pengujian dari node partitioner untuk menguji dan memprediksi status tagihan (*predict late payments*) pada data baru yang belum pernah dilihat sebelumnya.

Tahap akhir dari *workflow* ini berfokus pada agregasi dan visualisasi hasil prediksi. Keluaran dari node predictor dialirkan ke node **GroupBy** untuk menghitung dan mengelompokkan jumlah total frekuensi hasil prediksi berdasarkan kelas kategorinya (*count predicted classes*). Hasil agregasi tersebut kemudian diteruskan ke node **Bar Chart** yang menyajikan distribusi frekuensi kelas prediksi (*predicted class distribution*) dalam bentuk grafik batang interaktif, sehingga memudahkan pemangku kepentingan dalam memahami proporsi tagihan yang diprediksi tepat waktu (*on-time*) versus terlambat (*late payment*).